

FastGraphGen: Uma Interface Baseada em IA Generativa para Visualização Dinâmica de Dados do DATASUS


Sérgio L. Lemos Junior¹, Renato Campos Mauro¹

¹Centro Federal de Educação Tecnológica Celso Suckow da Fonseca - CEFET/RJ

sergio.lemos@aluno.cefet-rj.br

renato.mauro@cefet-rj.br

Figura 1. Ilustração de Apresentação do Projeto



Abstract. With the popularization of generative Artificial Intelligences (AI) like ChatGPT and Google Gemini, Large Language Models (LLM) are becoming increasingly common and practical tools in various fields, including scientific research. In particular, we are increasingly seeking specific uses of AI in research and analysis of large databases to understand and study how diseases like Tuberculosis affect the Brazilian population. Therefore, this work aims to complement a project focused on the Brazilian Unified Health System (SUS), responsible for conducting data research and generating graphs related to Tuberculosis, but now implementing a LLM focused exclusively on graph generation, to integrate the interface and generate more precise and customizable graphs, using only natural language.

Resumo. Com a popularização de Inteligências Artificiais (IAs) generativas como o ChatGPT e o Google Gemini, as Large Language Models (LLMs) se tornam ferramentas cada vez mais comuns e práticas de serem usadas em diversas áreas, inclusive em pesquisas científicas. Em especial, buscamos cada vez mais usos específicos das IAs em pesquisas e análise de grandes bancos de dados para entendermos e estudarmos como doenças como a Tuberculose (TB) afetam a população brasileira. Dessa forma, este trabalho se propõe a complementar um projeto voltado para o Sistema Único de Saúde (SUS), responsável por fazer pesquisas de dados e gerar gráficos referentes a Tuberculose, mas agora implementando uma LLM voltada exclusivamente para geração de gráficos, para integrar a interface e gerar gráficos mais precisos e customizáveis, mediante apenas o uso de linguagem natural.

1. Introdução

A ascensão do uso das Inteligências Artificiais (IAs) no dia a dia tornou os Modelos de Linguagem de Grande Escala (LLMs) indispensáveis para diversas atividades, até mesmo pesquisas corporativas e científicas de alta complexidade [Li et al. 2024, Wang et al. 2025]. Contudo, os modelos generalistas que mais usamos, como ChatGPT e Google Gemini, não são tão práticos quando passamos a usá-los para propósitos mais específicos e que demandam maior precisão [Cheng et al. 2023]. Com isso em mente, pesquisadores têm investido em diversas frentes, tanto tentando otimizar o uso dessas LLMs para finalidades mais complexas, quanto tentando desenvolver seus próprios modelos focados em resolver essas especificidades [Praneeth et al. 2024, Wu et al. 2024].

Entretanto, ambas abordagens apresentam uma problemática: mesmo desenvolvendo modelos de propósitos específicos, ainda estão sujeitos a interpretações errôneas e alucinações sobre algum contexto fornecido pelo usuário [V'azquez 2024]. E junto a isso, ainda precisamos lidar também com a geração de artefatos visuais, como gráficos e mapas, que sofrem das mesmas alucinações [Khan et al. 2025]. O melhor cenário possível, seguindo esse raciocínio, seria desenvolver uma LLM capaz de entender comandos diretamente através de linguagem natural, tanto para fazer consulta de dados quanto para gerar imagens coerentes com a pesquisa a ser feita [Praneeth et al. 2024].

A tuberculose, embora curável e evitável, permanece como uma grave ameaça à saúde pública, especialmente no Brasil [Brasil, Ministério da Saúde 2024, Brasil, Ministério da Saúde 2022]. Para auxiliar as pesquisas para combater a doença, O Departamento de Informática do Sistema Único de Saúde (DATASUS) possui ferramentas de agregação de dados como o Sistema de Informação de Agravos de Notificação (SINAN) e o Aplicativo de Tabulação de Dados do DATASUS (TABNET), responsáveis pelo registro sistemático, o monitoramento geográfico de surtos e a formulação de políticas públicas baseadas na análise técnica de ocorrências e hospitalizações de forma mais assertiva à população [Brasil, Ministério da Saúde]. A intensificação de estudos epidemiológicos reflete a urgência de compreender a dinâmica dessa e de outras doenças nas regiões brasileiras, desafio que se tornou ainda mais crítico e evidente após muitas pessoas com tuberculose não terem recebido o diagnóstico adequado durante a pandemia de Covid-19 [Brasil, Ministério da Saúde 2022]. Esse cenário reforça a necessidade de plataformas de informação transparentes e de fácil acesso para o controle efetivo e a prevenção ágil de novos surtos epidemiológicos.

O crescente uso das IAs generativas no ambiente acadêmico para a estruturação e visualização de dados ainda encontra alucinações e erros de contexto [Kim et al. 2023, Cheng et al. 2023]. Tentando superar esses problemas, pesquisadores têm adaptado LLMs com aplicações modulares e metodologias de processamento de prompts, além de analisar como diferentes grupos de usuários interagem com essas ferramentas [Ruan et al. 2025, Wang et al. 2025]. Estudos voltados para o comportamento das IAs em outras tarefas acadêmicas, como a recuperação de informações em grafos [Li et al. 2023, Lissandrini et al. 2022] e a autocorreção de códigos também se mostram importantes para entender o raciocínio desses modelos [Chen et al. 2023a], gerando insights fundamentais para aprimorar sua precisão e eficiência na resolução de problemas e na geração de análises científicas visuais.

Os trabalhos de [Chaves 2025] e [de Mesquita Faben 2026], visando ajudar na

análise epidemiológica da tuberculose no Brasil, integraram o processamento de linguagem natural à visualização dinâmica de dados. A pesquisa de [Chaves 2025] estabeleceu uma fundação em back-end ao implementar uma arquitetura baseada em LLMs e *Retrieval-Augmented Generation* (RAG) para converter linguagem natural em comandos *Structured Query Language* (SQL) precisos, garantindo respostas contextuais e minimizando inconsistências. O trabalho subsequente de [de Mesquita Faben 2026] desenvolveu uma camada em front-end, através de tecnologias como React e Observable Plot, e o sistema passou a transformar esses dados estruturados em artefatos visuais complexos, como mapas coropléticos e painéis interativos, além da exportação de código para a plataforma ObservableHQ, o que assegura a reprodutibilidade científica. E embora os testes com participantes comprovem a eficácia dessa arquitetura, ainda há desafios quanto à fronteira da inteligência artificial generativa, que demandaria mais flexibilidade e customização dos gráficos, além de mitigar alucinações, ambos campos onde ainda podemos pesquisar e aprimorar o sistema como um todo.

E assim, nosso trabalho dará continuidade a esse projeto, fazendo um upgrade na geração de gráficos. O projeto consiste em desenvolver uma nova secção do sistema onde o usuário poderá trabalhar exclusivamente gerando gráficos, tendo opções diferentes dos gráficos já gerados pela interface atual e podendo modificá-los conforme necessário, funcionando através de uma ponte entre o usuário e uma *Application Programming Interface* (API) de uma LLM. Isso vai permitir que o usuário gere gráficos a partir de uma única pergunta, enquanto a própria interface se encarrega de contatar a LLM e imprimir o gráfico na tela.

2. Fundamentação Teórica

Nesta sessão, explicaremos em detalhes os fundamentos teóricos necessários para compreender melhor do que se trata o trabalho. Serão explicados desde o contexto envolvendo a Tuberculose no Brasil até detalhes referentes à programação e lógica por trás das LLMs e interfaces desenvolvidas para o projeto.

2.1. Contexto da Tuberculose

A tuberculose é uma doença infecciosa, causada pela bactéria *Mycobacterium tuberculosis*, e é curável e evitável, mas ainda ameaça gravemente a saúde de muitas pessoas no mundo, especialmente no Brasil [Brasil, Ministério da Saúde 2022]. Sua transmissão ocorre principalmente pelo ar, como através da fala, espirros e tosse próximos a pessoas infectadas, e ela afeta principalmente os pulmões, podendo alcançar outras partes do corpo [Brasil, Ministério da Saúde 2022]. Mesmo com muitos avanços tecnológicos e farmacêuticos no tratamento, pesquisas mostram que a luta contra a doença ainda está longe do fim. Assim, o Plano Nacional pelo Fim da Tuberculose, apresentado pelo Ministério da Saúde, compromete-se a reduzir os casos até 2035 em todo o país [Brasil, Ministério da Saúde 2024].

Como plataforma de análise e agregação de dados, o Ministério da Saúde disponibiliza o Sistema de Informação de Agravos de Notificação (SINAN) para registrar e processar dados sobre doenças, incluindo a tuberculose. O SINAN agrega as informações provenientes das unidades de saúde em todo o país, permitindo avaliar a qualidade dos serviços e do atendimento prestado em cada região para poder delegar mais políticas pu-

blicas a quem necessita, além de também poder monitorar eventuais surtos da doença [Brasil, Ministério da Saúde].

Também nessa vertente, o Departamento de Informática do SUS (DATASUS) desenvolveu a ferramenta TABNET, amplamente utilizada para consulta e análise de dados epidemiológicos em diversas pesquisas brasileiras [Brasil, Ministério da Saúde]. Através dessa ferramenta, o usuário pode selecionar os dados desejados através de filtros e pesquisa direta, podendo acessar bases de dados estruturadas que contém informações sobre ocorrências, hospitalizações e mortalidade de doenças, incluindo a tuberculose.

Nas últimas décadas, pesquisas que tentam entender como as doenças ainda se mantêm ativas e se espalhando se tornaram mais intensas e comuns. Diversos estudos epidemiológicos descritivos e de retrospectiva tentam traçar o perfil da tuberculose em diferentes regiões e períodos de tempo no Brasil, tentando entender como e em quais localidades e épocas do ano ela tem maior incidência [Brasil, Ministério da Saúde 2024]. E, principalmente nos anos da pandemia da Covid-19, estima-se que mais de 10 milhões de pessoas tenham adquirido tuberculose, mas menos de 60% dos casos foram diagnosticados e registrados corretamente [Brasil, Ministério da Saúde 2022]. Ambos fatos reforçam a necessidade de termos as ferramentas certas e de fácil acesso para estudar e prevenir surtos epidemiológicos o mais rápido possível.

2.2. LLMs e Modelos de IA

Sabemos que uso das IAs generativas, como ChatGPT e Google Gemini, está crescendo no ambiente acadêmico para auxiliar na estruturação de dados e geração de códigos, inclusive na criação de gráficos e outros artefatos visuais [Wu et al. 2024]. Mas, apesar do alto potencial dessas ferramentas, elas ainda têm certas limitações, como alucinações e leituras erradas do contexto apresentado [Khan et al. 2025]. Buscando mitigar esses problemas, pesquisadores têm focado em desenvolver e adaptar sistemas de IA e LLM de diferentes formas. Seja traduzindo linguagem natural em código para facilitar o uso delas [Praneeth et al. 2024], ou com aplicações modulares que organizam e filtram os dados de forma mais eficiente para uma LLM [Yang et al. 2024, Dibia 2023], as descobertas feitas por essas pesquisas indicam um futuro promissor.

A eficiência de uma IA na criação de artefatos visuais está atrelada à forma como que os dados brutos são recebidos e processados pelos modelos, mas diferentes metodologias e formatos de prompts para inserir tabelas e arquivos também se mostram como um componente importante na hora da LLM gerar o contexto necessário [Shin et al. 2024]. Mas, além disso, também é de suma importância avaliar como diferentes grupos são capazes de utilizar esses sistemas e quais resultados eles alcançam [Ruan et al. 2025]. O objetivo é classificar os modelos por utilidade e traçar estratégias mais eficientes para gerar imagens focadas em análise científica [Wang et al. 2025].

E para além da geração de gráficos, há também estudos focados no comportamento das IAs em outras áreas da pesquisa, como a recuperação de informações em grafos estruturados [Li et al. 2024, Li et al. 2023] e a capacidade de autocorreção (debug) de seus próprios códigos [Chen et al. 2023a]. Entender como os LLMs raciocinam nessas situações e demais contextos fornece insights valiosos, que ajudam a aprimorar os mecanismos das IA para solucionar mais precisamente problemas relacionados a visualização de dados.

2.3. Artefatos Visuais e Design

A visualização de dados e como o cérebro decodifica informações visuais é um tópico pertinente para pesquisadores, tão importante quanto a filtragem e organização dos dados. Passamos a utilizar cada vez mais artefatos visuais, como mapas e gráficos, para ilustrar e ter uma melhor noção dos impactos desses dados, especialmente no contexto que estamos explorando. Saber usar os modelos corretos de gráficos para os contextos mais adequados, e escolher cores que favoreçam o entendimento dessas informações é o que pode tornar um gráfico bom ou ruim para uma pesquisa ou artigo [Franconeri et al. 2021].

A nossa visão compreende posições em eixos (como em gráficos de barras) com maior facilidade, mas falha ao entender ângulos e áreas (como em gráficos de pizza), fazendo com que a informação se perca, mesmo que de forma breve [Cleveland and McGill 1984]. Ainda que consigamos extrair padrões globais ou perceber diferenças menores, comparar dados individuais apenas com base no aspecto visual sobrecarrega a memória e a compreensão da informação. Portanto, um design eficaz em um gráfico deve respeitar a nossa arquitetura cognitiva, usando cores e agrupamentos espaciais que auxiliem a guiar a atenção e evitar ilusões quanto às informações apresentadas [Franconeri et al. 2021].

Antes mesmo de decodificar a informação, a visualização também deve ser capaz de capturar a atenção. A primeira impressão ao se analisar um infográfico forma-se em apenas 500 milissegundos, ditada principalmente pela sua complexidade visual e escolha de cores [Harrison et al. 2015]. E este julgamento também depende de quem e quando o gráfico está sendo visto, variando significativamente conforme a idade, gênero e escolaridade do público [Harrison et al. 2015]. Ou seja, tanto quanto passar a informação de forma clara, é importante pensar no design de um gráfico adaptando-o às preferências demográficas e o contexto em que o público terá contato com o gráfico.

Com a atenção capturada, o foco volta-se para facilitar que o público memorize as informações: Estudos apontam que incluir elementos pictóricos, ícones familiares e até “*chartjunk*” (enfeites visuais) torna os gráficos mais memoráveis, sem comprometer o entendimento da informação [Borkin et al. 2013, Bateman et al. 2010]. E usando técnicas de narrativa (“*data storytelling*”) a estes recursos, o público é guiado de forma persuasiva pelos dados, entendendo seu contexto e sua aplicação, sem depender de grandes blocos de texto ou preencher a tela de números [Segel and Heer 2010].

Por fim, a real praticidade da visualização se encontra em facilitar o raciocínio e a ação. Gráficos mal planejados ou que ignoram o entendimento da audiência podem acarretar em raciocínios que induzem a más decisões. Substituir abstrações complexas (como barras de erro tradicionais) por metáforas visuais mais intuitivas (como arranjos de ícones para populações), por exemplo, são alternativas interessantes que facilitam na compreensão geral de um gráfico [Padilla et al. 2018]. Assim, tanto especialistas quanto leigos conseguem interpretar cenários críticos e tomar decisões fundamentadas.

3. Trabalhos Relacionados

Nesta sessão, discutiremos projetos e pesquisas feitas acerca do tema. Algumas influenciaram e ajudaram no desenvolvimento do projeto atual, enquanto outras tem uma correlação direta, sendo parte integral do mesmo.

3.1. Pesquisas sobre IAs e LLMs

Partindo de um levantamento preliminar de artigos feitos no Elicit, podemos observar que as IAs generativas se tornam mais presentes no meio acadêmico, tanto como objeto de estudo quanto para a estruturação de dados ou para a geração de códigos [Wang et al. 2025]. Pesquisas mais recentes questionam se essas ferramentas possuem a precisão e a criatividade necessárias para elaborar gráficos estatísticos complexos e coesos [V'azquez 2024]. Embora tenhamos modelos de propósito geral que demonstram muito potencial graças a seu treinamento, como o ChatGPT e Google Gemini, o que observamos é que eles ainda têm suas limitações, como alucinações e falhas de interpretação de contexto [Kim et al. 2023, Cheng et al. 2023]. Por isso, essas IAs devem ser encaradas atualmente como ferramentas de auxílio, enquanto tentamos compreender e aprimorar suas reais capacidades para solucionar esse tipo de problema de forma mais precisa no futuro.

Buscando contornar essas limitações, um dos principais pontos estudados atualmente é poder tornar a criação de gráficos e outros artefatos visuais um processo mais acessível e objetivo, encurtando a distância entre a linguagem natural e as linguagens de programação [Praneeth et al. 2024]. Existem pesquisas recentes voltadas ao desenvolvimento de sistemas integrados a LLMs capazes de traduzir comandos em texto para códigos funcionais de Python e Excel, dentre outras funcionalidades [Wu et al. 2024]. E por muitas vezes, essas ferramentas funcionam em conjunto com sistemas de avaliação automática e benchmarks próprios, comprovando sua agilidade e eficiência no trabalho de pesquisadores e usuários experientes [Chen et al. 2023b].

Ainda dentro dessa proposta, há também projetos focados em estruturar o fluxo de trabalho com o auxílio das IAs, através de aplicações modulares que organizam e filtram os dados de maneira automática antes da geração visual [Dibia 2023]. Nesse raciocínio, fragmentar o processamento dos dados para a criação de artefatos visuais não só maximiza o uso de uma LLM, como também previne eventuais alucinações ao apresentar todas as informações de uma vez só [Yang et al. 2024]. Isso permite aos usuários customizarem melhor o processo de criação dos gráficos, podendo integrar a IA que lhe for mais conveniente, além de permitir uma maior flexibilidade com o resultado final.

Outro aspecto muito pesquisado atualmente é a mecânica de como os modelos recebem e processam os dados brutos na hora de gerar imagens e visualizações. Diferentes metodologias e formatos de prompts são testados em algumas pesquisas para entender a maneira mais eficiente de alimentar essas IAs com tabelas e demais arquivos para criar o contexto necessário [Shin et al. 2024]. De forma mais generalizada, as pesquisas indicam que o sucesso da visualização depende fortemente de como as informações são inseridas, sendo os modelos de inferência os mais adequados para a tarefa, especialmente quando o sistema tem algum tipo de mecanismo de iteração em seu processamento [Khan et al. 2025].

Como forma de garantir a eficácia desse tipo de abordagem, pesquisadores têm realizado avaliações amplas e diversificadas, incluindo a testagem de diferentes arquiteturas e modelos de linguagem, bem como observando como diferentes grupos conseguem utilizar os sistemas e interfaces desenvolvidos [Ruan et al. 2025]. A partir disso, estão sendo propostas formas de classificar os modelos de acordo com sua verdadeira utilidade e traçar estratégias de uso mais eficientes, refinando a aplicabilidade dessas IAs para gerar

imagens voltadas para pesquisas e análises científicas.

Por fim, também vale ressaltar as pesquisas que vão além dos gráficos estatísticos tradicionais, explorando o comportamento das IAs em outras frentes do trabalho científico. Por exemplo, estudar a capacidade das IAs de traduzir comandos para a manipulação e recuperação de informações em grafos de conhecimento estruturados [Li et al. 2024, Lissandrini et al. 2022], ou como se comportam ao realizar a autocorreção (debug) de seus próprios códigos [Chen et al. 2023a]. Entender como os modelos executam essas tarefas de outros contextos também nos garante insights interessantes sobre seu raciocínio, ajudando a aprimorar sua interpretação de contextos complexos na visualização de dados.

3.2. Projetos Anteriores

Inicialmente, [Chaves 2025] propôs em seu trabalho que poderíamos usar técnicas de recuperação de dados combinadas com LLMs para auxiliar a pesquisa e análise estatística de dados epidemiológicos sobre a tuberculose. Através dos dados disponibilizados pelo DATASUS [Brasil, Ministério da Saúde], e combinando as tecnologias de LLM e RAG, o modelo é capaz de converter linguagem natural em comandos SQL que fazem a busca e filtragem dos dados, trazendo-os ao usuário final já prontos para análise. O projeto proposto se mostrou uma ferramenta útil para os pesquisadores, permitindo uma análise mais objetiva e aprofundada sobre os impactos da tuberculose no Brasil e como ela vem sendo tratada, trazendo respostas alinhadas com o contexto e sem alucinações nas respostas. Entretanto, ainda faltava trabalhar uma interface mais amigável e funcional para que esse projeto alcançasse ainda mais pesquisadores e se tornasse mais eficiente.

Pensando nisso, [de Mesquita Faben 2026] se propôs a desenvolver uma camada de front-end para o sistema de análise epidemiológica, materializando painéis de controles interativos via web. O projeto também abrange uma infraestrutura de back-end, responsável por processar dados estruturados do DATASUS e criar artefatos visuais, como mapas coropléticos e gráficos de barras, de forma dinâmica e interativa, utilizando as bibliotecas React e Observable Plot. Dessa forma, as funcionalidades desenvolvidas permitem aos usuários, usando apenas linguagem natural, pesquisar e desenvolver gráficos de interesse em painéis personalizados e exportar seu código-fonte para a plataforma ObservableHQ, permitindo a reprodutibilidade. Testes com 21 participantes demonstram que a usabilidade e familiarização da interface com os usuários foi bem aceita, e que é capaz de auxiliar na interpretação visual de dados epidemiológicos. Porém, ainda assim, a geração de gráficos apresenta limitações quanto a customização ou edição dos gráficos gerados, além de ocasionais alucinações.

A partir disso, esse trabalho se propõe a desenvolver um novo “motor” para geração de gráficos e artefatos visuais para o projeto desenvolvido anteriormente por [Chaves 2025] e [de Mesquita Faben 2026]. O projeto consiste em desenvolver uma nova janela, dentro da interface já estabelecida, onde o usuário, a partir dos dados do DATASUS, poderá gerar diferentes tipos de gráficos, mais específicos, e modificá-los conforme necessário. A nova janela funcionará como uma ponte de comunicação entre o usuário e uma API de uma LLM, de forma que o usuário precise apenas selecionar o tipo de gráfico que desenha e mandar uma pergunta, em linguagem natural, e a nova janela seja capaz de se comunicar com a API para solicitar, receber e imprimir o gráfico de forma prática e

rápida, além de permitir que o mesmo usuário faça alterações no design do gráfico dentro desse mesmo chat.

4. Trabalho Anterior

Este trabalho tem como objetivo final desenvolver um novo sistema focado na geração de gráficos e outros artefatos visuais, e integrá-lo à interface desenvolvida por [de Mesquita Faben 2026] para o projeto prévio de [Chaves 2025], portanto, deve estar funcionando corretamente com ambas partes desenvolvidas anteriormente, fazendo algumas adaptações necessárias. Nesta seção, revisaremos brevemente o funcionamento dos dois trabalhos anteriores e então introduziremos o que será feito de novo para o projeto.

4.1. Back-end Anterior

Este projeto propõe uma arquitetura voltada à análise de dados epidemiológicos fornecidos pelo DATASUS utilizando LLM (Gemini 1.5 Flash) integrados a uma pipeline de RAG focada em bancos relacionais (Text-to-SQL), ou seja, funciona convertendo linguagem natural em comandos SQL. Diferente de abordagens RAG anteriores, que se focavam mais em bancos vetoriais e busca semântica em textos não estruturados, o sistema extrai, transforma e carrega (ETL) dados em um banco PostgreSQL, utilizando o LLM para orquestrar consultas exatas. A engenharia por trás da solução ficou organizada da seguinte forma:

1. **Roteamento Semântico:** Para otimizar custos e tempo antes do RAG efetivamente começar, o fluxo de input passa por um LLM Router, onde há uma classificação zero-shot para instruir o LLM a categorizar a query do usuário em três branches de execução: (1) Mensagem Geral (requisições que o próprio world knowledge do LLM é capaz de resolver), (2) Continuação (requisições que dependem de contexto prévio porém não muito extenso ou complexo no banco de dados), e (3) Consulta Nova (requisições completamente novas que vão afetar o banco de dados em si, acionando então o Text-to-SQL).
2. **RAG Relacional:** Como o esquema relacional possui menos de 30 tabelas, o limite de tokens suporta a injeção integral da estrutura no contexto, assim a arquitetura descarta o uso de bancos vetoriais (Dense Retrieval). Ao identificar uma Consulta Nova, o sistema injeta o schema completo do PostgreSQL, regras de negócio e metadados necessários diretamente no system prompt, condicionando o modelo. O LLM então infere a query SQL, validando sua sintaxe validada; e falhas encontradas na compilação causam um early-stopping do fluxo e retorna um pedido de reformulação ao usuário, evitando que um código inválido ou danoso seja executado.
3. **Tratamento de Alucinações:** Após executar o SQL de forma bem-sucedida, os dados tabulares resultantes vão para o back-end, de forma assíncrona, e começa a geração final. O sistema faz uma nova chamada ao LLM contendo somente a pergunta original e o os dados tabulares da query. O prompt aplica diretivas de strict grounding, onde o modelo fica proibido de complementar respostas com generalizações ou seu conhecimento de mundo pré-treino. Se os dados tabulares forem vazios ou insuficientes, o LLM é forçado a barrar o procedimento.
4. **Pipeline de Ingestão (ETL Assíncrono):** Por fim, para garantir a coerência dos dados que alimentam o RAG, o back-end roda um ETL rigoroso de extração e

transformação. Utilizando a biblioteca PySUS via FTP, arquivos granulares são obtidos no formato Parquet e então são transformados via Pandas. Durante esse processo, atributos categóricos numéricos são mapeados semanticamente para seus significados reais usando o dicionário oficial do SINAN, o que agiliza o pareamento léxico do LLM na criação das queries SQL subsequentes.

De fato, todo o sistema desenvolvido traz uma enorme facilidade para pesquisadores analisarem e trabalharem com os dados do SUS. Porém, ainda era necessário trabalhar uma interface mais amigável e objetiva para se fazer todo o procedimento. A partir disso, começamos a falar sobre a incrementação nesse sistema, com o front-end feito por [de Mesquita Faben 2026].

4.2. Front-end Anterior

Este projeto aprimora a infraestrutura de back-end baseada em LLM e RAG, introduzindo uma camada de visualização interativa de dados (IDIV - Interactive Data and Information Visualization). A arquitetura converte as respostas textuais e os dados tabulares extraídos em painéis de controle dinâmicos baseados em web. E através de React, Vite e da biblioteca Observable Plot, foi desenvolvido um front-end que unifica essas funcionalidades, ajudando os pesquisadores ao traduzir os dados brutos em insights visuais instantâneos. A engenharia do projeto ficou estruturada da seguinte forma:

1. **Recomendação de Visualização (VisualizationRecommenderHandler):** Para transpor a limitação de respostas textuais, o fluxo do back-end foi aprimorado com uma nova classe que atua como um mecanismo de recomendação. Após a geração da resposta textual, o LLM analisa as características dos dados recuperados e gera um *JavaScript Object Notation* (JSON) estruturado. Este objeto contém os dados e um score de relevância (de 0 a 1) para diferentes tipos de representações visuais (gráficos de barras, linhas ou mapas coropléticos), para que a interface renderize gráficos que melhor preservam a integridade semântica da consulta.
2. **Renderização Dinâmica e Arquitetura front-end (React + Observable Plot):** Através de hooks de estado do React, o front-end intercepta os dados classificados com score superior a 0,8, advindos do objeto JSON, e os mapeia dinamicamente para os componentes da biblioteca Observable Plot. A arquitetura emprega injeção de propriedades para modularizar a criação de mapas coropléticos (utilizando matrizes GeoJSON do Brasil) e gráficos quantitativos. Dessa forma, o usuário pode alternar de representações textuais para visuais fluidamente através de sobreposições (pop-ups) interativas, dado o design centrado em componentes da interface.
3. **Exportação de Código e Reprodutibilidade (Integração ObservableHQ):** Diferente de painéis de Business Intelligence fechados (como Tableau), o projeto foi planejado com foco na transparência e extensibilidade para equipes multidisciplinares. O sistema armazena não apenas o estado visual, mas também expõe o código-fonte exato (em JavaScript) utilizado para a geração do gráfico. Isso permite que pesquisadores exportem diretamente a matriz de dados e a lógica de renderização para ambientes de sandbox externos, como a plataforma ObservableHQ, garantindo a reprodutibilidade científica.

Após o desenvolvimento do projeto, sua eficácia na transição de uma interface de texto para uma abordagem IDIV foi validada empiricamente através da métrica System

Usability Scale (SUS). Com testes aplicados em 21 usuários, a interface obteve um escore médio de 82,5, classificação de nota “Excelente” segundo a métrica. A análise das respostas indicou uma minimização significativa na curva de aprendizado e na complexidade percebida, provando que a orquestração entre prompts de dados estruturados (JSON) e a renderização reativa (React) do front-end resultou em uma ferramenta de inteligência epidemiológica altamente intuitiva e de baixo esforço cognitivo.

Ainda assim, havia espaço para mais incrementações no projeto, especialmente no que tange a geração de artefatos visuais. A implementação do objeto JSON agilizou o processo, mas ainda é um pouco limitada caso seja necessário fazer alterações ou correções em eventuais alucinações que o LLM pode causar. Assim, nessa linha de raciocínio, nosso projeto começa seu desenvolvimento.

4.3. Novo Sistema de Gráficos


Para fazer o upgrade na função de geração de gráficos apresentada no front-end de [de Mesquita Faben 2026], implementaremos uma nova janela na interface já estabelecida, cuja função será fazer uma ponte entre o sistema atual e a API de uma LLM para gerar novos gráficos. Essa ponte funcionará pegando a opção de gráfico escolhida e a pergunta feita pelo usuário, montando um prompt ao redor dela, enviando-o para a LLM e então recebendo de volta o gráfico gerado e imprimindo-o na interface. Essa ponte também será capaz de enviar ao LLM comandos para que o gráfico gerado possa ser alterado a partir da pergunta inicial. Como pode ser visualizado na Figura 2, o fluxo do novo sistema está estruturado da seguinte forma:

1. Nova Janela: A ferramenta de geração de gráficos se apresenta em uma nova janela se , acessível por um botão circular no canto direito superior da interface principal. Ela possui uma caixa para entrada de texto, onde o usuário primeiramente faz a pergunta para gerar o gráfico e poderá fazer alterações no design do gráfico gerado; e adicionando uma barra na parte superior contendo as cinco opções de geração de gráfico disponíveis: Gráfico de Linhas, Barras Agrupadas, Gráfico de Setores, Heatmap e Automático, com a última sendo uma opção que deixa a cargo da LLM configurada decidir qual tipo de gráfico mais se adéqua para responder a pergunta do usuário. Quando o gráfico é gerado, o usuário tem a opção de baixá-lo em seu computador nos formatos SVG ou PNG. Por fim, a interface também apresenta um botão de limpar a conversa para que o usuário faça outra pergunta e gere outros gráficos.
2. Geração de Prompt: Ao abrir essa nova janela, o usuário deve escolher uma opção de gráfico dentre cinco disponíveis e então escrever a pergunta que deseja ser respondida através de um gráfico. Ao clicar para enviar a pergunta, um script coleta a opção de gráfico escolhida e a primeira mensagem que o usuário enviar e a transforma em um prompt, adicionando frases e palavras para que o foco seja gerar o tipo de gráfico selecionado. Então, o script vai identificar quais partes da base de dados são mais relevantes para responder à pergunta feita pelo usuário e selecionar um recorte para ser enviado junto com o prompt API de uma LLM configurada.
3. Comunicação com a API: Na API da LLM, o prompt e o recorte do banco de dados serão utilizados para gerar um código em Vega Lite, no formato JSON, que é o responsável por gerar o gráfico desejado. Esse JSON é retornado para o script,

que ficará responsável então por interpretá-lo e “transformá-lo” em uma imagem, que então será devolvida para a nova janela, onde será impressa para o usuário.

4. Ajustes nos Gráficos: Demais mensagens que forem enviadas dentro da janela são enviadas diretamente para a API, funcionando como pequenos prompts que servem para ajustar o código do gráfico gerado. Essa função serve principalmente para permitir que o usuário faça alterações mais rápidas de cores ou design do gráfico que possam favorecer o que ele vai contar em sua pesquisa. Ademais, nessa etapa, o usuário também pode escolher limpar a conversa para gerar um gráfico completamente novo, configurando um modelo ou recorte do banco de dados diferente.

Figura 2. Fluxograma do Funcionamento do Sistema



Um componente fundamental para o funcionamento do sistema como um todo foi definir qual API e qual modelo de LLM deveríamos usar para viabilizar o projeto. Considerando a acessibilidade da API e sua capacidade de gerar gráficos, dentro dos modelos e configurações gratuitas possíveis, foi escolhido usar a API Groq em conjunto com o modelo *llama-3.3-70b-versatile*, que se mostrou bastante acessível e rápido durante os primeiros testes, além da facilidade de se criar uma chave de acesso para a API.


5. Desenvolvimento

Nesta secção, será explicado todo o processo de desenvolvimento do novo sistema, desde a definição do design da interface até os trechos de código utilizados para fazer a comunicação.

5.1. Adaptando a Interface

Dado que o projeto desenvolvido anteriormente por [Chaves 2025] e [de Mesquita Faben 2026] já possui uma interface não só funcional e estável como também visualmente agradável, foi necessário um certo tempo para primeiro pensar como poderíamos integrar a nova janela à interface sem comprometer o funcionamento do que já existe e mantendo coerência visual. Dessa forma, a Figura 3 ilustra os três designs pensados inicialmente:


Figura 3. Três Protótipos de Design para Interface Integrada



1. Design 1: Ao fazer uma pergunta para o chat e receber uma resposta, há um botão ao lado dela, e, ao clicar nele, será gerado um gráfico referente à pergunta/resposta.
2. Design 2: Perto do botão de enviar mensagens, há um interruptor/switch onde é possível ligar ou desligar a função de gerar gráficos. Deixando-o desligado, o chat funciona como sempre, e a resposta vem apenas em forma de texto. Ligando-o, a resposta vem junto com uma imagem que mostra o gráfico referente à pergunta feita.
3. Design 3: Inspirado pela função Canva do Google Gemini, há uma aba no canto direito da tela, e ao interagir com ela, é aberto um chat paralelo, cuja função é exclusivamente gerar gráficos que correspondam à pergunta feita pelo usuário.

Após debater um pouco, foi decidido que seguiríamos com a ideia de design 3, dado que traria um novo elemento para interface, com uma funcionalidade nova interativa, mas mantendo a estética geral e as ideias desenvolvidas anteriormente. Algumas alterações foram feitas pensando em facilitar o desenvolvimento em Radix UI, baseado em React, assim chegando ao resultado final apresentado na Figura 4:

Figura 4. Design Final Escolhido Para Interface Integrada



O design da interface adaptada mantém a coesão com o resto da interface ao mesmo tempo que é simples e objetivo, sem causar confusão ao usuário que for usar esse novo sistema.

5.2. Desenvolvimento do Código e Integração

Como foi explicado, o novo sistema funciona como uma ponte entre a interface e uma API rodando no Groq. A principal parte dessa conexão ocorre através de um script em JavaScript responsável por fazer a passagem de informações entre as duas partes: ele “decora” a pergunta do usuário com um texto pré-estabelecido, transformando-a em um prompt que será enviado e interpretado pela API. Depois, esse script recebe a resposta da API e extrai

o JSON referente ao gráfico. Além disso, esse script também é responsável por armazenar a chave da API e o modelo a ser utilizado pelo Groq. No Código 1, apresentamos um pseudocódigo sobre a construção do prompt a partir da pergunta do usuário.

1. Pseudo-Código de Conexão com o Groq

```
1 DICCIONARIO INSTRUcoes_DE_GRAFICO:
2   "line": "Gere um gráfico de linhas (mark: line)..."
3   "bar_grouped": "Gere um gráfico de barras agrupadas (mark:
4     bar com dodge/facet)..."
5   "pie": "Gere um gráfico de setores (mark: arc)..."
6   "heatmap": "Gere um mapa de calor (mark: rect)..."
7   "auto": "Analise a pergunta e escolha automaticamente o
8     melhor gráfico."
9
10 FUNCAO construir_prompt_inicial(pergunta_do_usuario,
11   dados_tabela, tipo_de_grafico):
12   instrução_visual = INSTRUcoes_DE_GRAFICO[tipo_de_grafico]
13
14   SE dados_tabela não for nulo:
15     secao_de_dados = "Use EXATAMENTE estes dados reais do
16       DATASUS: " + dados_tabela
17   SENAO:
18     secao_de_dados = "Não há dados reais. Crie estimativas
19       epidemiológicas plausíveis baseadas no seu
20       conhecimento."
21
22   RETORNA "Você é especialista em dados epidemiológicos.
23     Pergunta: " + pergunta_do_usuario +
24     " Tipo solicitado: " + instrução_visual +
25     " Dados a usar: " + secao_de_dados +
26     " Retorne APENAS um JSON Vega-Lite V5 válido e
27     completo."
```


E com o design da nova interface definida, foi desenvolvido um novo componente em Radix UI, em JavaScript, para complementar a janela de chat, criando a barra azul que pode ser expandida para acessar o novo chat que trabalha com a geração de gráficos. No Código 2, apresentamos um pseudocódigo sobre o funcionamento dos componentes da nova interface.

2. Pseudo-Código do Painel Azul (Nova Janela)

```
1 COMPONENTE SeletorDeGrafico(tipo_selecionado, ao_mudar,
  desabilitado):
2   RENDERIZAR Botoes de Rádio: [Linhas, Barras Empilhadas,
    Barras Agrupadas, Setores, Heatmap, Automático]
3
4 COMPONENTE PainelAzul(dados_reais):
5   estado: historico_chat = []
6   estado: especificacao_atual = NULO
7   estado: eh_primeira_mensagem = VERDADEIRO
8   estado: tipo_de_grafico = "Automático"
9
10  FUNCAO limpar_chat():
11    historico_chat = []
12    eh_primeira_mensagem = VERDADEIRO
13    especificacao_atual = NULO
14    tipo_de_grafico = "Automático"
15
16  FUNCAO enviar_mensagem(texto_do_usuario):
17    ADICIONAR texto_do_usuario ao historico_chat
18    MOSTRAR "Gerando gráfico..." no historico_chat
19
20    SE eh_primeira_mensagem == VERDADEIRO:
21      prompt = construir_prompt_inicial(texto_do_usuario,
        dados_reais, tipo_de_grafico)
22    SENAO:
23      prompt = construir_prompt_ajuste(texto_do_usuario,
        especificacao_atual)
24
25    TENTAR:
26      resposta_da_ia = chamar_API_Groq(prompt)
27      nova_especificacao_vega_lite = extrair_json(
        resposta_da_ia)
28
29      especificacao_atual = nova_especificacao_vega_lite
30      eh_primeira_mensagem = FALSO
31      REMOVER "Gerando gráfico..." do historico_chat
32
33      SE dados_reais for NULO:
34        ADICIONAR "Aviso: Dados do DATASUS indisponíveis
          . Gráfico baseado em estimativas." ao
          historico_chat
35
36      ADICIONAR nova_especificacao_vega_lite ao
          historico_chat // Inicia Renderização
37    CAPTURAR erro:
38      REMOVER "Gerando gráfico..." do historico_chat
39      ADICIONAR "Erro ao gerar gráfico." ao historico_chat
```

Com código e script funcionando corretamente, a Figura 5 apresenta imagens de como as telas se apresentam durante o uso da interface. Nelas, podemos ver o usuário gerando um gráfico novo a partir de uma pergunta, e depois uma alteração no tamanho do título do gráfico feito pelo usuário em outro prompt.

Figura 5. Telas de Captura do Funcionamento da Nova Interface



Dessa forma, a nova janela responsável pela ponte com a API se conecta de forma natural com a interface já estabelecida, mas também cria um ambiente fácil de se entender e se usar para gerar os gráficos. A interface funciona de forma prática e objetiva, podendo utilizar o sistema anteriormente desenvolvido e a nova janela de forma paralela, o que permite a verificação de dados em tempo real. A responsividade do sistema se mostra bastante rápida, seja para gerar ou modificar um gráfico já gerado.

6. Testes e Resultados

Por fim, nesta seção, discutiremos sobre os testes feitos para averiguar a qualidade dos gráficos gerados e o funcionamento geral da nova interface. Em um primeiro momento, foram feitos alguns testes localmente, com uma demanda menor e por quem entendia melhor como manusear o sistema desenvolvido. Depois, foi aberto um formulário para um público mais amplo, composto majoritariamente por estudantes, para que fossem feitas avaliações e testes com voluntários. Todas as perguntas utilizadas nos testes individuais e com voluntários foram retiradas e adaptadas a partir de um arquivo disponibilizado contendo perguntas pré-definidas dedicadas a testes do programa desenvolvido [Chaves 2025, de Mesquita Faben 2026].

6.1. Testes Individuais

Inicialmente, rodamos por volta de 10 testes individuais, para compreender a responsividade do Groq em relação à geração de dados. Foram feitas diversas perguntas de diferentes escopos, e mudando as configurações de qual gráfico deveria ser gerado. Como forma de carregar as tabelas necessárias no banco de dados e verificar se os gráficos estão sendo gerados com as informações corretas, sempre fazemos primeiro a pergunta no chat principal e depois a repetimos no painel azul. Dessa forma, escolhemos alguns exemplos para ilustrar os resultados:

1. Figura 6: Gráfico de Barras (gerado ao selecionar a opção “Automático”) que responde à pergunta “Qual a taxa de coinfeção TB-HIV por estado ou região?”
2. Figura 7: Gráfico de Barras Agrupadas gerado para responder à pergunta “Qual a distribuição de casos de tuberculose por faixa etária e sexo?”
3. Figura 8: Gráfico de Setores gerado para responder à pergunta “Qual a distribuição dos tipos de formas extrapulmonares (pleural, ganglionar, óssea etc.)?”
4. Figura 9: Gráfico Heatmap gerado para responder à pergunta “Qual a distribuição dos tipos de formas extrapulmonares (pleural, ganglionar, óssea etc.) por Faixa Etária?”

Figura 6. Gráfico para Taxa de Coinfecção TB-HIV por Estado ou Região (opção “Automático”)




Figura 7. Gráfico para Distribuição de Casos de Tuberculose por Faixa Etária e Sexo (opção “Barras Agrupadas”)




Figura 8. Gráfico para Distribuição dos Tipos de Formas Extrapulmonares de Tuberculose no Brasil (opção “Gráfico de Setores”)

Distribuição dos tipos de formas extrapulmonares de tuberculose no Brasil





Figura 9. Gráfico para Intensidade de Formas Extrapulmonares por Faixa Etária (opção “Heatmap”)

Intensidade de Formas Extrapulmonares por Faixa Etária



Em uma observação inicial, podemos perceber que as informações apresentadas nos gráficos estão de acordo com as informações do banco de dados, não está havendo alucinações. Quanto aos visuais dos gráficos, todas as opções disponíveis geram gráficos coerentes e entendíveis para o tipo escolhido. Entretanto, a resolução da imagem quando salvamos o PNG para alguns modelos, como por exemplo Heatmap, se demonstra reduzida e difícil de ler em algumas instâncias. Quanto a velocidade, todos os tipos de gráfico se mostraram rápidos de gerar por parte da API do Groq.

6.2. Testes com Voluntários

Para os testes com voluntários, foi montada uma arquitetura onde o front-end roda na plataforma Netlify, o back-end roda na plataforma Render, e o banco de dados roda na plataforma Neon, todas com assinatura a nível gratuito. Com um site rodando o sistema, também foi desenvolvido um breve formulário onde os usuários deveriam testar as funções do painel azul, todos colocando as mesmas três perguntas e configurações pré-determinadas:

1. Pergunta 1: Qual a distribuição de casos de tuberculose por sexo nos anos de 2021, 2022 e 2023? - Opção “Barras Agrupadas”;
2. Pergunta 2: Qual a proporção de casos novos, recidivas, reingressos e transferências? - Opção “Gráfico de Setores”;
3. Pergunta 3: Há alguma correlação entre tipos de formas extrapulmonares (pleural, ganglionar, óssea etc.) e o sexo dos pacientes? - Opção “Heatmap”.

No restante do formulário, o voluntário é instruído a enviar as imagens dos três gráficos gerados e então responder algumas perguntas, tanto para entendermos o perfil dos usuários quanto para termos alguns comentários sobre eventuais problemas encontrados. Quatro das perguntas funcionam com uma escala de 1 a 5, três delas possuem 2 a 3 opções de “Sim” ou “Não” para responder, e as três últimas são comentários abertos para pessoa responder como preferir.

1. Qual o seu nível de familiaridade com ferramentas de análise de dados ou criação de gráficos (ex: Excel, Tableau, Python)? - Escala de 1 (baixo) a 5 (alto);
2. Você possui experiência na área da saúde ou com dados epidemiológicos? - Opções “Sim” ou “Não”;
3. Conseguiu acessar o site e seguir as instruções? - Opções “Sim, sem problemas”, “Sim, mas com alguns problemas”, e “Não consegui acessar”;
4. Como você classificaria a navegação pela interface e por suas funcionalidades? - Escala de 1 (muito difícil) a 5 (muito fácil);
5. Como você classificaria a qualidade da interface durante seu uso? - Escala de 1 (desagradável) a 5 (agradável);
6. A Inteligência Artificial conseguiu compreender o as perguntas e gerar gráficos coerentes? - Opções “Sim” ou “Não”;
7. Como você classificaria o tempo de resposta entre enviar o comando e o gráfico aparecer na tela ? - Escala de 1 (muito lento) a 5 (muito rápido);
8. Além das opções de gráficos disponíveis, você sentiu falta de algum formato específico? Comente abaixo - Resposta Curta;
9. Qual foi a maior dificuldade que você encontrou ao utilizar o sistema? - Resposta Curta;
10. Que sugestões de melhoria você daria para tornar essa ferramenta ainda mais útil e prática para pesquisadores? - Resposta Curta.f


Após disponibilizar o site e o formulário, houve uma certa instabilidade para acessar ao site, um problema relacionado a limitações de uso das chaves das APIs do Google Gemini e Groq, o que demandou alguns ajustes para comportar mais acessos. Após isso, os testes passaram a correr normalmente, e duraram dois dias, e tiveram 16 voluntários acessando a plataforma e respondendo as perguntas. A Figura 10 mostra como os voluntários se distribuem quanto às escalas de conhecimento de ferramentas de análise de

dados, variando entre 12,5% e 25% para cada categoria. Dos 16 voluntários, 3 deles (18,8%) eram pessoas com algum conhecimento na área da saúde, enquanto os outros 13 (81,2%) eram de outras áreas. Dentre todos eles, 87,5% conseguiram acessar normalmente a interface e realizar os testes, enquanto 12,5% deles relataram conseguir acessar mas encontrar algum problema durante o uso, mas nenhum deles relatou não estar conseguindo acessar o sistema.

Figura 10. Gráficos dos Resultados das Perguntas 1, 2 e 3 do Formulário


Qual o seu nível de familiaridade com ferramentas de análise de dados ou criação de gráficos (ex: Excel, Tableau, Python)?

16 respostas




Você possui experiência na área da saúde ou com dados epidemiológicos?

16 respostas



Conseguiu acessar o site e seguir as instruções?

16 respostas




A Figura 11 os resultados referentes ao uso da interface do painel azul em conjunto à interface do chat principal. Sobre a navegação e utilização da interface, 56,3% das avaliações se encontram na escala 5, enquanto o resto decresce entre as escalas 4 e 3. Sobre a qualidade visual da interface, também em uma escala de 1 a 5, as opiniões ficaram mais pulverizadas entre as escalas 3 a 5, mas 5 também é a com mais resultados, apresentando 68,8%.

Figura 11. Gráficos dos Resultados das Perguntas 4 e 5 do Formulário


Como você classificaria a navegação pela interface e por suas funcionalidades?

16 respostas



Como você classificaria a qualidade da interface durante seu uso?

16 respostas




Para as Perguntas 1 e 2, os gráficos gerados pelos voluntários apresentam uma boa consistência, tanto com seu design quanto com os dados apresentados nele. Nelas, os resultados apresentam algumas inconsistências quanto à escala ou cores dos gráficos de Barra Agrupadas e de Setores, mas ainda mantendo uma coerência com os dados apresentados. Entretanto, para a Pergunta 3, foi observado que alguns voluntários receberam um gráfico com informações faltando ou trocadas na escada do Heatmap, além de muitos também relatarem mensagens de erro ao tentar usar essa configuração. Como pode ser visto na Figura 12, para todos os testes, 93,8% dos voluntários relataram que a velocidade na geração dos gráficos foi bem rápida e satisfatória. Quanto a capacidade de compreensão das perguntas, apenas 1 dos voluntários (6,3%) relatou que as perguntas foram mal interpretadas e resultaram em gráficos com alucinações. Alguns exemplos seletos dos

gráficos gerados pelos voluntários pode ser visto na Figura 13, incluindo um erro com o gráfico Heatmap.

Figura 12. Gráficos dos Resultados das Perguntas 6 e 7 do Formulário

Como você classificaria o tempo de resposta entre enviar o comando e o gráfico aparecer na tela ?

16 respostas



A Inteligência Artificial conseguiu compreender o as perguntas e gerar gráficos coerentes?

16 respostas




Figura 13. Comparação Lado a Lado entre os Gráficos Gerados pelos Voluntários



E dentre outros comentários feitos em duas secções abertas para escrever, os principais pontos levantados pelos voluntários foram a dificuldade de navegar entre o chat principal e alguns elementos do design da interface que deixam a desejar ou dificultam sua utilização, como o contraste entre o fundo azul com as letras brancas e pequenas, ou a localização e aparência do botão que dá acesso ao painel azul. Houve alguns voluntários relatando também problemas para acessar o sistema através de dispositivos mobile.

1. “O Gerador de Gráficos e o Chatbot não eram distinguíveis, ao abrir a janela do gerador de Gráficos eu achei que estava na página inicial com Chatbot.”
2. “Não obtive dificuldades, mas a parte da interface está meio confusa.”
3. “As fontes estão um pouco pequenas e o contraste do azul com o branco também não ajuda. Também a parte de gerar gráficos poderia ser um botão escrito junto ao ícone e o nome dos arquivos ao fazer o download, o nome do gráfico.”
4. “Botão gerador de gráfico pode não ser tão obvio para algumas pessoas. É uma decisão de design a se considerar.”
5. “A página do site não é muito responsiva em telas menores (smartphones, notebooks com tela pequena.)”

7. Considerações Finais

Os testes com voluntários apontam que o sistema cumpre o seu propósito de criar gráficos de forma dinâmica e consistente dentro de uma interface amigável para diferentes tipos de usuário. Estando devidamente conectado ao banco de dados, as informações serão transpostas para diferentes tipos de gráficos, sem perder ou trocar informações escritas nele. O único modelo de gráfico que apresentou maiores problemas, o Heatmap, pode ser retrabalhado de forma a mitigar as alucinações de forma mais eficiente.

Entretanto, o sistema como um todo apresenta certos problemas atrelados ao uso de chaves de API de LLMs, como o Gemini para o funcionamento do back-end e o Groq para a geração de gráficos. O cenário ideal seria desenvolver uma LLM própria para o sistema, rodando em um servidor dedicado, responsável principalmente pela geração de gráficos e pelo tratamento das pesquisas feitas no banco de dados.

Ademais, com os comentários dos voluntários, também podemos perceber que há elementos visuais na interface do novo painel que podem ser otimizados. Fontes maiores, cores com contraste e saturação mais agradáveis aos olhos, e botões mais perceptíveis e didáticos para o usuário final. A geração de gráficos também pode receber melhorias quanto ao tamanho das fontes e de seus artefatos visuais, aproveitando melhor a área em que aparecem na tela. A adição de outros tipos de gráficos também pode ser interessante se pensarmos na aplicação do sistema em outras áreas além da saúde.

Referências

- [Bateman et al. 2010] Bateman, S., Mandryk, R. L., Gutwin, C., Genest, A., McDine, D., and Brooks, C. (2010). Useful junk?: the effects of visual embellishment on comprehension and memorability of charts. In *Proceedings of the 28th international conference on Human factors in computing systems - CHI '10*, Atlanta. ACM Press.
- [Borkin et al. 2013] Borkin, M. A., Vo, A. A., Bylinskii, Z., Isola, P., Sunkavalli, S., Oliva, A., and Pfister, H. (2013). What makes a visualization memorable? *IEEE Transactions on Visualization and Computer Graphics*.
- [Brasil, Ministério da Saúde] Brasil, Ministério da Saúde. Tabnet - datasus.
- [Brasil, Ministério da Saúde 2022] Brasil, Ministério da Saúde (2022). Brasil livre da tuberculose - plano nacional pelo fim da tuberculose como problema de saúde pública: estratégias para 2021-2025.
- [Brasil, Ministério da Saúde 2024] Brasil, Ministério da Saúde (2024). Plano nacional de saúde - pns 2024-2027.
- [Chaves 2025] Chaves, T. A. C. (2025). Uma abordagem com llm e rag para análise exploratória da tuberculose a partir de dados do datasus.
- [Chen et al. 2023a] Chen, X., Lin, M., Schärli, N., and Zhou, D. (2023a). Teaching large language models to self-debug. *ArXiv*.
- [Chen et al. 2023b] Chen, Z., Zhang, C., Wang, Q., Troidl, J., Warchol, S., Beyer, J., Gehlenborg, N., and Pfister, H. (2023b). Beyond generating code: Evaluating gpt on a data visualization course. *2023 IEEE VIS Workshop on Visualization Education, Literacy, and Activities (EduVis)*.
- [Cheng et al. 2023] Cheng, L., Li, X., and Bing, L. (2023). Is gpt-4 a good data analyst? *ArXiv*.
- [Cleveland and McGill 1984] Cleveland, W. S. and McGill, R. (1984). Graphical perception: Theory, experimentation, and application to the development of graphical methods. *Journal of the American Statistical Association*.
- [de Mesquita Faben 2026] de Mesquita Faben, M. S. (2026). O uso de gráficos para facilitar a interpretação de dados epidemiológicos: Estudo de caso da tuberculose no brasil.
- [Dibia 2023] Dibia, V. C. (2023). Lida: A tool for automatic generation of grammar-agnostic visualizations and infographics using large language models. *ArXiv*.
- [Franconeri et al. 2021] Franconeri, S. L., Padilla, L. M. K., Shah, P., Zacks, J. M., and Hullman, J. R. (2021). The science of visual data communication: What works. *Psychological Science in the Public Interest*.
- [Harrison et al. 2015] Harrison, L., Reinecke, K., and Chang, R. (2015). Infographic aesthetics: Designing for the first impression. *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems*.
- [Khan et al. 2025] Khan, S. R., Chandak, V., and Mukherjea, S. (2025). Evaluating llms for visualization tasks. *ArXiv*.

- [Kim et al. 2023] Kim, N. W., Ahn, Y., Myers, G., and Bach, B. (2023). How good is chatgpt in giving advice on your visualization design? *ACM Transactions on Computer-Human Interaction*.
- [Li et al. 2023] Li, H., Appleby, G., Brumar, C. D., Chang, R., and Suh, A. (2023). Knowledge graphs in practice: Characterizing their users, challenges, and visualization opportunities. *IEEE Transactions on Visualization and Computer Graphics*.
- [Li et al. 2024] Li, H., Appleby, G., and Suh, A. (2024). A preliminary roadmap for llms as assistants in exploring, analyzing, and visualizing knowledge graphs. *ArXiv*.
- [Lissandrini et al. 2022] Lissandrini, M., Mottin, D., Hose, K., and Pedersen, T. (2022). Knowledge graph exploration systems: are we lost? In *Conference on Innovative Data Systems Research*.
- [Padilla et al. 2018] Padilla, L. M. K., Creem-Regehr, S. H., Hegarty, M., and Stefanucci, J. K. (2018). Decision making with visualizations: a cognitive framework across disciplines. *Cognitive Research: Principles and Implications*.
- [Praneeth et al. 2024] Praneeth, B., Singh, A. K., Raju, J. K., Mohana, and Suma, B. (2024). Natural language interface for data visualization: Harnessing the power of large language models. *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*.
- [Ruan et al. 2025] Ruan, S., Sheng, R., Wen, X., Wang, J., Zhang, T., Wang, Y., Dwyer, T., and Li, J. (2025). Qualitative study for llm-assisted design study process: Strategies, challenges, and roles. *ArXiv*.
- [Segel and Heer 2010] Segel, E. and Heer, J. (2010). Narrative visualization: Telling stories with data. *IEEE Transactions on Visualization and Computer Graphics*.
- [Shin et al. 2024] Shin, S., Hong, S., and Elmqvist, N. (2024). Visualizationary: Automating design feedback for visualization designers using llms. *ArXiv*.
- [V’azquez 2024] V’azquez, P.-P. (2024). Are llms ready for visualization? *2024 IEEE 17th Pacific Visualization Conference (PacificVis)*.
- [Wang et al. 2025] Wang, P., Yu, Y., Chen, K., Zhan, X., and Wang, H. (2025). Large language model-based data science agent: A survey. *ArXiv*.
- [Wu et al. 2024] Wu, Y., Wan, Y., Zhang, H., Sui, Y., Wei, W., Zhao, W., Xu, G., and Jin, H. (2024). Automated data visualization from natural language via large language models: An exploratory study. *Proceedings of the ACM on Management of Data*, (3).
- [Yang et al. 2024] Yang, Z., Zhou, Z., Wang, S., Cong, X., Han, X., Yan, Y., Liu, Z., Tan, Z., Liu, P., Yu, D., Liu, Z., Shi, X., and Sun, M. (2024). Matplotlibagent: Method and evaluation for llm-based agentic scientific data visualization. *ArXiv*.